# Yingrui Hou

## Data science & ingénierie des données scientifiques

Clermont-Ferrand, France | yingrui.hou@outlook.com | +33(0)785396332
https://yingrui-hou.github.io/PersonalPage/

### Profil

Docteure en physique, avec expérience postdoctorale en analyse reproductible, validation de modèles et diagnostic de performance. Chaînes CatBoost et calibration de modèles appris. Partant de zéro sur TensorFlow, adaptation de code, ajout de modèles, vérification sur simulations et migration vers une station GPU partagée. Coordination et communication internationales au service de la data science et de l'ingénierie des données scientifiques.

### Compétences clés

- Évaluation : calibration de modèles d'apprentissage profond, validation de reconnaissance d'images, contrôles sur données réelles, diagnostics entraînement/test et correction des biais.
- Modélisation : vraisemblance, modèles de mélange, inférence statistique, analyse des incertitudes, CatBoost/gradient boosting, sélection de variables et repondération des distributions.
- Traitements : adaptation de code existant, composants réutilisables, Shell/YAML/CMake, Linux et configuration/gestion d'une station GPU partagée.
- Programmation et calcul : Python, NumPy, pandas, scikit-learn, statsmodels ; C/C++, ROOT/RooFit ; TensorFlow et calcul numérique sur GPU.

### Expérience de recherche

**Chercheuse postdoctorale | 2021–2026**

CNRS — LAPP, Annecy (2021–2023) ; LPC/LPCA, Clermont-Ferrand (2023.12.01–2026.05.31). Recherche au sein des collaborations LHCb et GRAiNITA.

- Construction de chaînes Python/C++/ROOT réutilisables pour préparer les données, extraire des signaux faibles et valider les résultats sans étiquette par événement.
- Entraînement de classifieurs CatBoost ; contrôle des variables, réponses entraînement/test et seuils, avec modèles et configurations sauvegardés pour réutilisation.
- Alignement des jeux de données simulés, de contrôle et cibles par repondération avec gradient boosting et calibration ; prise en compte des écarts résiduels dans les incertitudes.
- Évaluation et optimisation sur données réelles d'un modèle de clustering ECAL ; recherche des causes des écarts pour orienter la calibration et le suivi logiciel.

**Formation par la recherche doctorale | 2016–2021**

University of Chinese Academy of Sciences — master et doctorat intégrés en physique des particules. Formation à la formulation quantitative des problèmes, au calcul scientifique, à la validation expérimentale et à la communication des résultats.

### Formation

- Master et doctorat intégrés en physique des particules — University of Chinese Academy of Sciences, 2016–2021.
- Licence en physique appliquée — China University of Mining and Technology, 2010–2014.

## Projets et résultats

### Diagnostic des écarts de performance

Contrôle sur données réelles d'un modèle de reconnaissance d'images pour le clustering ECAL. Investigation des écarts instrumentaux et de reconstruction, avec documentation pour la calibration et le suivi logiciel. Méthode transférable : relier l'évaluation du modèle au diagnostic des causes.

### Calibration des sorties de modèles appris

Validation et calibration sur données réelles d'un modèle de marquage de saveur par apprentissage profond. Méthode transférable : vérifier la fiabilité des sorties avant leur utilisation dans une nouvelle analyse.

### Apprentissage et décalage de distribution

Entraînement de classifieurs CatBoost avec contrôles entraînement/test et études de seuils. Repondération pour aligner les distributions de contrôle et cibles avant l'inférence. Méthode transférable : valider le comportement lorsque les échantillons diffèrent.

### Apprentissage de TensorFlow et mise en œuvre GPU

Apprentissage de TensorFlow sur code existant ; portage personnel des amplitudes, ajout des effets d'efficacité, résolution et biais, puis validation face à un code C++ éprouvé aux mêmes points. Écarts résolus en harmonisant les types ; comparaison simulation-données par tests KS. Station GPU partagée configurée en une demi-journée, puis exécution GPU en une autre demi-journée. Participation aux tests du fitter développé par un collaborateur.

Pour le marquage de saveur et le clustering ECAL, participation aux discussions de construction et d'entraînement en vue de la calibration et de la validation ; sans réalisation de leur entraînement.

## Apprentissage, réalisation et collaboration

- Apprentissage par la pratique : extension d'un code TensorFlow inconnu avec de nouveaux modèles, puis vérification du code sur simulations ; CatBoost et Geant4 dans d'autres projets.
- Réalisation : accord sur les interfaces et variables avant développement ; révision collective des priorités et délais face aux difficultés nouvelles du traitement des données.
- Collaboration : GitLab et revues croisées de merge requests ; détection d'une erreur de signe du fitter par vérification mathématique. Planification hebdomadaire et échanges techniques rapides ; présentations GDR-InF 2022 et FCC/DRD France 2025.

Première mission proposée : convenir de la décision et des critères de réussite, vérifier les données, établir une référence et livrer une étude de validation ciblée avec conclusions et prochaines étapes.

## Langues et mobilité

Chinois : langue maternelle | Anglais : C1 | Français : B1–B2. Voyages à vélo au long cours ; mobilité en Europe.

## Références des projets

- Diagnostic des écarts de performance (https://yingrui-hou.github.io/PersonalPage/index-fr.html#work-6)
- Calibration des sorties de modèles appris (https://yingrui-hou.github.io/PersonalPage/index-fr.html#work-9)
- Apprentissage et décalage de distribution (https://yingrui-hou.github.io/PersonalPage/index-fr.html#work-3)
- Apprentissage de TensorFlow et mise en œuvre GPU (https://yingrui-hou.github.io/PersonalPage/index-fr.html#work-8)