Yingrui Hou

Data science & ingénierie des données scientifiques

Clermont-Ferrand, France | yingrui.hou@outlook.com | +33(0)785396332
https://yingrui-hou.github.io/PersonalPage/

Profil

Docteure en physique, avec expérience postdoctorale en analyse Python/C++, calcul TensorFlow/GPU et validation ML sur données réelles. Association de l'inférence statistique, de traitements réutilisables et de la calibration de modèles d'apprentissage profond. Adaptation aux nouveaux problèmes, coordination de tâches et présentation des résultats en équipe internationale. Cible : data science et ingénierie des données scientifiques.

Compétences clés

- Programmation et calcul : Python, NumPy, pandas, scikit-learn, statsmodels ; C/C++, ROOT/RooFit ; TensorFlow et calcul numérique sur GPU.
- Modélisation : vraisemblance, modèles de mélange, inférence statistique, analyse des incertitudes, CatBoost/gradient boosting, sélection de variables et repondération des distributions.
- Traitements : composants réutilisables, Shell/YAML/CMake, Linux, revue de code partagé et configurations d'analyse reproductibles.
- Évaluation : calibration de modèles d'apprentissage profond, validation de reconnaissance d'images, contrôles sur données réelles, diagnostics entraînement/test et correction des biais.

Expérience de recherche

Chercheuse postdoctorale | 2021–2026

CNRS — LAPP, Annecy (2021–2023) ; LPC/LPCA, Clermont-Ferrand (2023.12.01–2026.05.31). Recherche au sein des collaborations LHCb et GRAiNITA.

- Développement de chaînes Python/C++/ROOT réutilisables reliant préparation des données, extraction de signaux faibles, ajustements de vraisemblance et validation en l'absence de vérité terrain par événement.
- Construction de chaînes de sélection CatBoost avec contrôles des variables, comparaisons entraînement/test et études de seuils ; sauvegarde des modèles et configurations pour une application reproductible.
- Alignement des jeux de données simulés, de contrôle et cibles par repondération avec gradient boosting et calibration ; prise en compte des écarts résiduels dans les incertitudes.
- Évaluation et optimisation sur données réelles du modèle de clustering ECAL ; investigation d'écarts de reconstruction pour orienter la calibration et les corrections logicielles.

Formation par la recherche doctorale | 2016–2021

University of Chinese Academy of Sciences — master et doctorat intégrés en physique des particules. Formation à la formulation quantitative des problèmes, au calcul scientifique, à la validation expérimentale et à la communication des résultats.

Formation

- Master et doctorat intégrés en physique des particules — University of Chinese Academy of Sciences, 2016–2021.
- Licence en physique appliquée — China University of Mining and Technology, 2010–2014.

Projets et résultats

Calcul scientifique TensorFlow/GPU

Construction et évaluation de densités de probabilité à amplitudes complexes pour une mesure conjointe de gamma, avec TensorFlow et accélération GPU. Application du calcul numérique à un modèle statistique complexe.

Calibration de modèles d'apprentissage profond

Validation et calibration d'un modèle de marquage de saveur à partir de données réelles, pour relier les sorties du modèle appris à l'analyse physique ultérieure.

Performance d'un modèle de reconnaissance d'images

Contrôle et optimisation sur données réelles du modèle de clustering de l'ECAL de LHCb au Run 3. Investigation des écarts de reconstruction et documentation des résultats pour la calibration et le suivi logiciel.

Apprentissage et décalage de distribution

Construction de classifieurs CatBoost avec contrôles entraînement/test, études de seuils et repondération d'échantillons pour aligner données de contrôle et cibles avant l'inférence.

Pour le marquage de saveur et le clustering ECAL, participation aux discussions de construction et d'entraînement en vue de la calibration et de la validation ; sans réalisation de leur entraînement.

Apports de la recherche à l'ingénierie

- Adaptation et apprentissage : application de l'inférence, de CatBoost, de TensorFlow/GPU et de Geant4 à différents problèmes par la bibliographie, l'implémentation et les contrôles sur données.
- Coordination : organisation de tâches liées de mesure, d'analyse et de validation, avec composants réutilisables et hypothèses documentées.
- Présentation et collaboration : communications au GDR-InF 2022 et à FCC/DRD France 2025, dont au nom de GRAiNITA ; contributions au code partagé et aux revues techniques.

Langues et mobilité

Chinois : langue maternelle | Anglais : C1 | Français : B1–B2. Voyages à vélo au long cours ; mobilité en Europe.

Références des projets

- Calcul scientifique TensorFlow/GPU (https://yingrui-hou.github.io/PersonalPage/index-fr.html#work-8)
- Calibration de modèles d'apprentissage profond (https://yingrui-hou.github.io/PersonalPage/index-fr.html#work-9)
- Performance d'un modèle de reconnaissance d'images (https://yingrui-hou.github.io/PersonalPage/index-fr.html#work-6)
- Apprentissage et décalage de distribution (https://yingrui-hou.github.io/PersonalPage/index-fr.html#work-3)