Yingrui Hou

Data science & ingénierie des données scientifiques

Clermont-Ferrand, France | yingrui.hou@outlook.com | +33(0)785396332
https://yingrui-hou.github.io/PersonalPage/

Profil

Docteure en physique, avec une expérience postdoctorale dans le développement de chaînes Python/C++ pour des données expérimentales bruitées. Association de l'inférence statistique, de l'apprentissage automatique, de la préparation des données et de la validation de modèles pour produire des résultats reproductibles. Adaptation de méthodes à différentes problématiques, coordination de tâches d'analyse liées et présentation des résultats en équipe internationale. Cible : postes de data science et d'ingénierie nécessitant des traitements réutilisables et une validation rigoureuse.

Compétences clés

- Données et programmation : Python, NumPy, pandas, scikit-learn, statsmodels, matplotlib/seaborn ; C/C++, ROOT/RooFit.
- Modélisation : vraisemblance, modèles de mélange, inférence statistique, analyse des incertitudes, CatBoost/gradient boosting, sélection de variables et repondération des distributions.
- Ingénierie des traitements : composants réutilisables, analyses pilotées par configuration, Shell/YAML/CMake, Linux, revue de code partagé et application reproductible des modèles.
- Validation : diagnostics entraînement/test, études de seuils, échantillons de contrôle, calibration, correction des biais et recherche des causes.

Expérience de recherche

Chercheuse postdoctorale | 2021–2026

CNRS — LAPP, Annecy (2021–2023) ; LPC/LPCA, Clermont-Ferrand (2023.12.01–2026.05.31). Recherche au sein des collaborations LHCb et GRAiNITA.

- Développement de chaînes Python/C++/ROOT réutilisables reliant préparation des données, extraction de signaux faibles, ajustements de vraisemblance et validation en l'absence de vérité terrain par événement.
- Construction de chaînes de sélection CatBoost avec contrôles des variables, comparaisons entraînement/test et études de seuils ; sauvegarde des modèles et configurations pour une application reproductible.
- Alignement des jeux de données simulés, de contrôle et cibles par repondération avec gradient boosting et calibration ; prise en compte des écarts résiduels dans les incertitudes.
- Investigation d'écarts de reconstruction à l'aide de canaux de référence et de comparaisons données/simulation ; identification de problèmes instrumentaux et logiciels orientant les corrections.

Formation par la recherche doctorale | 2016–2021

University of Chinese Academy of Sciences — master et doctorat intégrés en physique des particules. Formation à la formulation quantitative des problèmes, au calcul scientifique, à la validation expérimentale et à la communication des résultats.

Formation

- Master et doctorat intégrés en physique des particules — University of Chinese Academy of Sciences, 2016–2021.
- Licence en physique appliquée — China University of Mining and Technology, 2010–2014.

Projets et résultats

Apprentissage automatique et décalage de distribution

Problème : les échantillons d'entraînement et de calibration ne représentaient pas naturellement les événements cibles. Implémentation de classifieurs CatBoost, de contrôles des scores et de repondérations dans une chaîne cohérente. Les comparaisons entraînement/test ont permis de vérifier le surapprentissage avant le choix du seuil ; l'alignement a étayé l'inférence ultérieure.

Inférence tenant compte des biais de mesure

Implémentation de composantes de vraisemblance pour l'efficacité de sélection et la résolution, avec corrections distinctes pour Run 1 et Run 2. L'alignement des échantillons de contrôle, les ajustements conjoints et les vérifications d'incertitude rendent les hypothèses explicites et réutilisables. Compétences transférables à la modélisation statistique et à l'évaluation des risques liés aux modèles.

Transformation de mesures en entrées de modèle

Construction d'une chaîne mesure-simulation : cartes de réponse dépendant de la position issues d'essais sous faisceau, puis intégration dans l'analyse Geant4/C++. Contribution des non-uniformités au terme constant de résolution en énergie inférieure à 1 % dans l'étude du premier prototype GRAiNITA. Résultat propre à ce prototype et à cette étude collective.

Apports de la recherche à l'ingénierie

- Adaptation et apprentissage : passage de l'inférence par vraisemblance à la sélection CatBoost et à la modélisation Geant4 ; articulation de la bibliographie, de l'implémentation et des vérifications sur données pour aborder de nouveaux problèmes.
- Coordination de travaux de recherche : organisation de tâches liées, depuis les mesures jusqu'aux résultats validés, avec composants réutilisables et hypothèses documentées pour les revues de collaboration.
- Présentation et collaboration internationale : communications au GDR-InF 2022 et au 5e atelier FCC/DRD France en 2025, dont une au nom de GRAiNITA ; contributions au code partagé et aux revues techniques.

Langues et mobilité

Chinois : langue maternelle | Anglais : C1 | Français : B1–B2. Voyages à vélo au long cours ; mobilité en Europe.

Références des projets

- Apprentissage automatique et décalage de distribution (https://yingrui-hou.github.io/PersonalPage/index-fr.html#work-3)
- Inférence tenant compte des biais de mesure (https://yingrui-hou.github.io/PersonalPage/index-fr.html#work-2)
- Transformation de mesures en entrées de modèle (https://yingrui-hou.github.io/PersonalPage/index-fr.html#work-4)